

#### Trabalho realizado por:

- → Pedro Ramos
  - > NºMec: 107348
- → Daniel Madureira
  - > N°Mec: 107603



# ÍNDICE

INTRODUÇÃO	
PROPOSIÇÃO DO PROBLEMA	
METODOLOGIA DO CÓDIGO	
ESTRUTURAS DE DADOS UTILIZADAS	
FLUXO DE EXECUÇÃO	5
ARGUMENTOS	ε
IDENTIFICAR OS PROCESSOS RELEVANTES	9
FUNÇÕES	11
usage	11
generateArray	12
O PROBLEMA DO ARRAY BIDIMENSIONAL	
COMPARAÇÃO DE DATAS	13
readWriteData	14
O PROBLEMA	
A SOLUÇÃO	
clearArray	18
sortArray	
printArray	20
RESULTADOS E TESTES	
CONCLUSÃO	25
WEBGRAFIA	26

### INTRODUÇÃO

# PROPOSIÇÃO DO PROBLEMA

O propósito deste trabalho prático é criar um script em *bash* que consiga identificar **processos** relevantes e mostrar as estatísticas da utilização do espaço de armazenamento de cada uma deles, ou seja, o número de *bytes* lidos e escritos por cada processo em *s* segundos.

Neste documento iremos apresentar a nossa abordagem e descrever a metodologia do código utilizado.

# METODOLOGIA DO CÓDIGO

Para chegar aos resultados esperados, o nosso programa deve realizar as seguintes operações:

- → Analisar e validar os argumentos obrigatórios e opcionais introduzidos;
- → Obter os Process IDs relevantes dos processos a correr no sistema com base nos argumentos escolhidos e na informação encontrada sobre o processo;
- → Gerar um array 2D com a informação necessária sobre cada processo baseado no seu ID:
- → Ordenar o array segundo os critérios escolhidos (taxa de leitura ou taxa de escrita);
- → Apresentar o array ao utilizador.

### ESTRUTURAS DE DADOS UTILIZADAS

O nosso programa utiliza essencialmente 4 estruturas de dados para realizar as operações necessárias:

→ Várias variáveis (c, u, s, e, etc.) que guardam os valores dos argumentos passados ao programa e processados pelo 'getops';

```
# Default Values, podem ser sobreescritos pelo utilizador

c=".*"  # Regex para filtrar processos pelo seu COMM

u=".*"  # Regex para filtrar processos pelo seu USER

s="0"  # Data mínima inicial dos processos

e="0"  # Data máxima inicial dos processos

m=0  # PID mínimo dos processos

M=0  # PID máximo dos processos

p=0  # Num máximo de processos a mostrar

w=0  # Ordenar a tabela pela taxa de escrita

r=0  # Ordenar a tabela inversamente
```

→ Um vetor PIDVector que guarda os Process IDs encontrados inicialmente;

0	363	4	1076
1	397	5	1235
2	545	6	2890
3	986		

→ Um array associativo procData que guarda os dados processados de cada PID relevante. Este array funciona como um array de 2 dimensões na nossa implementação;

_	545	Ь	2890
3	986		

declare -A procData

Index	Comm	User	PID	
1	Python	Root	363	
2	Firefox	User1	545	
3	Spotify	User2	986	

→ Uma variável maxProc que contem o número total de PIDs no array e que é atualizada quando este muda.

### FLUXO DE EXECUÇÃO

function qenerateDataArr() {} function readWriteData() function clearArray() {} function sortArray() {} function printArray() {}

#### Gerar a maior parte do array

> generateDataArr procData

### Ler e fazer a média das taxas read/write

> readWriteData maxProc

### Remover as entradas do array que não interessam

> clearArray procData maxProc

#### Ordenar o array

> sortArray procData maxProc

### Apresentar o *array* na forma de tabela

> printArray procData

#### ARGUMENTOS

Para aumentar o potencial do código e a sua utilidade para o utilizador numa situação real, o código deve adaptar-se aos requisitos do utilizador.

Para tal é necessário utilizar uma ferramenta que possa transmitir as variáveis introduzidas pelo utilizador para o código em si. Assim, usamos a função do sistema *getopts* para obter os argumentos opcionais introduzidos pelo utilizador.

```
SYNOPSYS

getopts optstring name [arg...]

DESCRIPTION

The getopts utility shall retrieve options and option- arguments from a list of parameters. [...]

Each time it is invoked, the getopts utility shall place the value of the next option in the shell variable specified by the name operand and the index of the next argument to be processed in the shell variable OPTIND.

from: getopts(1p) - Linux manual Page.
```

A função getopts vai processar os seguintes argumentos opcionais:

 -h Mostra ao utilizador as operações possíveis.

```
# Mostrar a usagem caso seja requesitado
h)
    usage
    ;;
```

-c<regex> Filtra os processos de acordo com o **seu nome**.

-u<regex> Filtra os processos de acordo com o nome de utilizador;

```
# Data minima inicial do processo
s)
s=${OPTARG}
(( ${#s} != 0 )) || usage
;;
```

-s<data> Elimina os processos cuja data de início seja menor que a especificada;

```
# Regex a aplicar sobre o nome do
# utilizador do processo
u)
   u=${OPTARG}
;;
```

```
Elimina os processos cuja
-e<data>
                                          e)
            data de início seja maior
                                              e=${OPTARG}
            que a especificada;
                                              (( ${#e} != 0 )) || usage
            Elimina os processos cujo
-m<int>
            Process ID seja menor que
                                            m)
                                                m=${OPTARG}
            o integer especificado;
                                                ((m > 0)) || usage
-M<int>
            Elimina os processos cujo
                                           M)
            Process ID seja maior que
                                               M=${OPTARG}
            o integer especificado;
                                               ((M > 0)) || usage
-p<int>
            Determina o número de
            processos a mostrar na
                                              p=${OPTARG}
                                              ((p > 0 || p < 1000)) || usage
            tabela final:
            Ordena
                     a
                         tabela
                                  final
-w
            em ordem
                             taxa
                                    de
                         à
            escrita ao invés da ordem
            à taxa de leitura (default);
            Inverte
                           ordem
                                    da
                      а
- L
            tabela final:
                                               r=1
            Apenas
Outro
                        mostra
                                    as
```

Na nossa implementação, o **último argumento** é sempre o tempo **entre as duas leituras** para as taxas de escrita e leitura.

usage

argumento operações possíveis.

Após o getopts processar os argumentos iniciais (começados por "-") a variável "\$\*" ganha o valor das opções que não foram processadas, que neste caso é o número de segundos pretendido.

```
# Tempo entre as duas leituras das taxas read/write
updateTime="${*}"
```

Após obter todos os argumentos, os valores que definem conjuntos de PIDs/Datas tem de ser testados para garantir que são válidos.

O último argumento (tempo entre leituras) também é verificado, tendo este de pertencer a {1, 2, ..., 1000}.

```
if [[ "$M" -ne "0" ]] && [[ "$m" -ne "0" ]]; then
    # Asserta que "M" é maior ou igual que "m"
    ((M >= m)) || usage
fi
if [[ "$s" -ne "0" ]] && [[ "$e" -ne "0" ]]; then
    # Asserta que "s" é menor ou igual a "e"
    (( $(date -d "${s}" +%s) <= $(date -d "${e}" +%s) )) || usage
fi

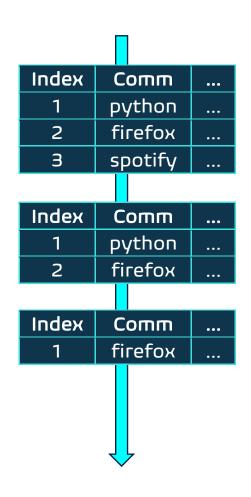
# Testar se o ultimo argumento (segundos entre leituras)
# não foi utilizado, ou é inválido
if [[ "$*" -eq "" ]] || [[ "${updateTime}" =~ '^[0-9]+$' ]] ||
    [[ "${updateTime}" -lt 1 ]] || [[ "${updateTime}" -gt 1000 ]]; then
    usage
fi</pre>
```

# IDENTIFICAR OS PROCESSOS RELEVANTES

Para a execução do código essencial do projeto, devemos primeiro identificar os processos relevantes e obter os seus respetivos Process IDs, preenchendo assim o PIDVector.

No nosso código a eliminação de processos ocorre gradualmente ao longo da execução, removendo processos com base na informação que temos sobre eles a cada momento (ex: não precisamos de esperar até obtermos o Start Date de um processo se já sabemos que este não cumpre o regex do Comm).

Logo, a remoção de processos da nossa tabela final é feita **separadamente ao longo do percurso do código**, sacrificando simplicidade em benefício de uma maior eficiência.



Para preencher o vetor PIDVector inicial **utilizamos o comando "ps"**, mas o comando **"pgrep"** também pode ser utilizado.

Com o comando "ps" temos de eliminar o cabeçalho da tabela que este retorna com o comando "tail". Com a tabela resultante podemos aplicar o comando "awk", que usaremos para verificar o nome do processo e o seu utilizador contra o regex especificado através dos argumentos opcionais, sendo este um exemplo de remoção de processos ao longo do código.

```
# ps com PID, user, comm | ignorar cabeçalho |
PIdVector=($(sudo ps -Ao pid,user,comm | tail -n +2 |
   awk -v userName="$u" -v comName="$c" '$3~comName && $2~userName { print $1 }' ))
# user e comm filtrados com regex output só os PIDs selecionados
```

Deste modo conseguimos remover imediatamente PIDs que iriam **aumentar exponencialmente o tempo de execução** das funções seguintes, visto que estas iteram sobre todos os PIDs recebidos múltiplas vezes, logo quanto mais rápido "limparmos" os PIDs a tratar, melhor.

## FUNÇÕES

O nosso código está dividido em várias funções para melhor encapsular e descrever o fluxo do programa.

#### USAGE

A função usage simplesmente imprime no terminal um menu com a explicação da utilização do programa.

Aqui o utilizador pode descobrir quais as operações possíveis que este pode introduzir, se necessitam de argumento e qual o objetivo de cada uma delas. **Esta função também acaba a execução do código**, visto que ela é chamada quando existe algum erro nos argumentos introduzidos (**exit code 1**).



#### GENERATEARRAY

Esta função utiliza o array de Process IDs "PIDVector". A função **itera sobre cada PID capturado** e verifica:

- → Se o programa tem acesso aos ficheiros necessários para analisar o processo em questão (e se eles existem);
- → Se o processo escreveu ou leu algo desde que foi chamado, pois processos sem leitura ou escrita não são relevantes;
- → Se o PID pertence ao conjunto (m; M) definido pelo utilizador (isto só é verificado caso "m" ou "M" tenham sido definidos);
- → Se a data de criação do processo pertence ao conjunto (s;e) definido pelo utilizador (isto só é verificado caso "s" ou "e" tenham sido definidos).
- → Se um processo passa por estes critérios, a informação adicional deste é lida e colocada no array bidimensional procData. O número total de processos apanhados, "maxProc", é também incrementado.

#### O PROBLEMA DO ARRAY BIDIMENSIONAL

Para guardar as informações de cada processo, a nossa implementação usa um **array de bidimensional**.

O problema é que, em bash, não existem arrays com mais do que uma dimensão, ou seja, o endereçamento de um array do tipo "arr(3)=16" é possível, mas um endereçamento do tipo "arr(3)(2)=16" já não é.

Felizmente, encontrámos uma forma de passar por esta limitação com o uso de **arrays associativos**, que funcionam como um dicionário (de python) ou uma hash table, ao **associar um valor não a um index, mas sim a uma string**.

Com isto pudemos converter **arr(3)(2)=16** para **arr("3,2")=16**, que é muito fácil de realizar em *bash* visto que a esta **trata todas as variáveis como se fossem apenas de um** *type*, fazendo a conversão de 2 números para "int1, int2" sem problemas.

#### Por exemplo:

```
for i in $(seq 0 $(( numProcMax - 1 ))); do
    procRead=($(sudo cat /proc/${procPId}/io | g
    procWrite=($(sudo cat /proc/${procPId}/io |
        procData[$i, 1]=${procRead#-}
        procData[$i, 2]=${procWrite#-}
        done
```

Neste caso, se \$i fosse 3, estaríamos a endereçar o valor de procData ("3, 1") e ("3, 2").

É de notar que o array procData está dividido da seguinte forma:

Index	0	1	2	3	4	5	6	7
пРгос	Comm	User	PID	ReadB	WriteB	RateR	RateW	Date

#### COMPARAÇÃO DE DATAS

Para comparar datas é utilizado o comando "date –d \$varData +%s", que transforma as datas num número int de segundos desde 1/1/1970 (epoch time) até à data definida na variável.

Sendo assim, é possível facilmente comparar **qualquer data como se fosse um valor int** (o "date" aceita vários formatos de datas diferentes).

A data do processo é dada pela data de criação da sua pasta /proc/PID, que podemos obter com o "ls -ld" e "awk".

Para preencher a informação necessária de cada processo precisamos ainda de obter o **nome do processo**, contido no ficheiro **/proc/PID/comm** e o **nome do utilizador que o chamou**, contido na informação **de quem criou a pasta /proc/PID**.

```
procComm=($(sudo cat /proc/${procPId}/comm))
procUser=($(stat --format '%U' /proc/${procPId}))

procData[$maxProc, 0]=${procComm}
procData[$maxProc, 1]=${procUser}
procData[$maxProc, 2]=${procPId}
procData[$maxProc, 7]=${procDate[@]}

# Num total de processos analisados
((maxProc=maxProc+1))
#fi
```

#### READWRITEDATA

A função readWriteData **lê os dados de leitura e escrita** de cada processo e coloca os resultados no array de dados procData.

Após completar isto, a função **calcula quanto tempo demorou** a realizar este ciclo inicial, e dorme durante o tempo especificado pelo utilizador.

Quando a função acorda, **volta a ler os dados de leitura/escrita** de cada processo e **calcula a sua média** (taxa de leitura e escrita). Os valores dos dados totais escritos e lidos também são atualizados.

A função começa por **guardar em \$t1 o tempo inicial** (*epoch* com milissegundos).

Após isto a função **itera pelos processos** no array bidimensional procData, copiando o PID de cada processo (coluna 2 no array procData) e **copiando os valores do número de carateres lidos e escritos** pelo processo para as colunas vazias 5 e 6 do procData.

Estes valores são obtidos do ficheiro /proc/PID/io, a que pudemos aceder e retirar a informação necessária com os comandos "cat", "grep" e "awk".

Depois de terminar a leitura, **é calculado o tempo que o ciclo "for" demorou a correr**. Isto vai ser útil para resolver o grande problema desta função, mencionado mais à frente.

Após percorrer os processos pela primeira vez, **a função espera o tempo especificado e volta a iterar pelos processos**, lendo outra vez o número de carateres que cada processo leu e escreveu e colocando os dados nas colunas vazias 3 e 4 do procData.

Finalmente, os processos são corridos uma terceira vez, na qual a função lê os valores guardados nas colunas 3 a 6 do procData (preenchidas com os dados de leitura e escrita) e, armazenando-as de novo no procData (escrevendo por cima dos valores das colunas 3 a 6, visto que estes já não serão precisos).

```
# Fazer as médias de lida/escrita
for i in $(seq 0 $(( numProcMax - 1 ))); do

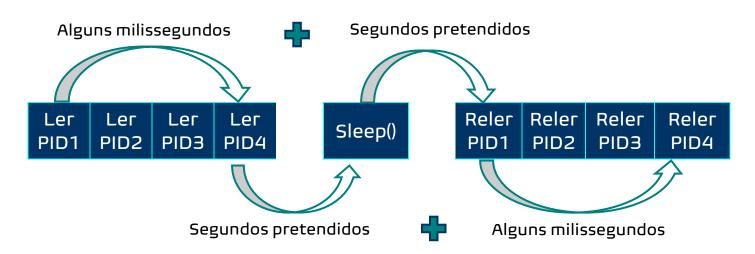
# Difrença entre as duas leituras
    numRead="$(( procData[$i, 3] - procData[$i, 5] ))"
    numWrite="$(( procData[$i, 4] - procData[$i, 6] ))"

# Taxas lida/escrita
    numMedioRead="$(( numRead / updateTime ))"
    numMedioWrite="$(( numWrite / updateTime ))"

# Atualiza-mos a escrita e lida total só por conveniência
    procData[$i, 3]=${numRead#-}
    procData[$i, 4]=${numWrite#-}
    procData[$i, 6]=${numMedioRead#-}
    procData[$i, 6]=${numMedioWrite#-}
done
```

#### O PROBLEMA

O tempo que a função espera entre as leituras não pode ser exatamente o tempo especificado pelo utilizador, visto que, por exemplo, o primeiro PID a ser iterado no primeiro ciclo "for" vai ter de esperar os segundos especificados mais o tempo que demora a percorrer os outros PIDs (antes de chegar ao sleep), o que levaria a que os cálculos das médias fossem incorretos. O mesmo acontece para todos os outros PIDs, sendo que o tempo a mais é exatamente o tempo de correr um dos ciclos "for".



#### A SOLUÇÃO

Para resolver isto, pudemos calcular o tempo que o primeiro ciclo "for" demora a ser executado e removê-lo do tempo total a esperar antes de percorrer o próximo "for". Esta solução não é absolutamente correta visto que os dois ciclos "for" não tem tempos de execução exatamente iguais.

O terceiro ciclo "for", que calcula os valores das diferenças e das médias, só existe para fazer os dois primeiros ciclos "for" demorarem aproximadamente o mesmo tempo a serem executados, para que o resultado seja muito mais próximo do correto. Caso contrário, as ações executadas no terceiro ciclo "for" poderiam ser absorvidas para o segundo ciclo "for".

É de notar que os **cálculos do tempo de espera são feitos através do** "awk" visto que a *bash* não consegue calcular nativamente valores numéricos decimais ("float" ou "double") e o "sleep" apenas aceita valores em segundos e não milissegundos.

#### CLEARARRAY

A função clearArray é a **última etapa de remoção de processos** do array procData.

Esta função remove os processos do array em que não foi detetada nenhuma atividade de leitura ou escrita ao longo do código, ou seja, nos quais as taxas de leitura e escrita foram nulas.

Como tecnicamente o nosso array procData é associativo, uma vez que arrays bidimensionais não existem em *bash*, não é possível remover uma linha do array sem ter de mudar a "chave" das linhas consequentes, logo a melhor forma de atualizar o array removendo as linhas pretendidas é ao criar um array novo temporário e no fim escrever esse array temporário por cima do array procData.

```
# Clonar o array temporário para procData
unset procData
declare -gA procData
for key in "${!tempArray[@]}"; do
    procData[$key]=${tempArray[$key]}
done
maxProc=${indexTemp}
return
```

#### SORTARRAY

A função sortArray utiliza o **algoritmo do tipo "Bubble sort" para ordenar o array** de dados de acordo com as **taxas de leitura** (ou escrita, se o utilizador assim definir).

Outros algoritmos seriam mais rápidos, mas visto que são muito mais complexos de traduzir para bash, e que o número de processos relevantes nunca é muito grande (sempre inferior a 200), a diferença de tempo não seria notável o suficiente para justificar a criação dum algoritmo muito mais complexo.

#### PRINTARRAY

O printArray imprime o array de dados final através de um ciclo for.

Este ciclo começa na linha 0 e **incrementa** um contador até chegar à linha final ou até mostrar o número de linhas especificado.

Caso o argumento "-p <int>" seja especificado, o ciclo acaba após a linha número p seja alcançada.

Caso o argumento "-r" seja especificado, o ciclo **começa por mostrar a linha final e decrementa** até chegar ao número pretendido de linhas ou até ao início do array (reverte o array).

```
# Função que imprime o array no formato de tabela
function printArray() {
    declare -n local dataArray="$1" # Cópia local de procData
    local start=0  # Número da linha inicial
    local increment=1  # Incremento (positivo ou negatívo)
    local end=$(( ${#dataArray[@]} / 8 )) # Número da linha fin

# Determinar o fim da tabela caso "-p <int>" seja definido
    if [[ "$p" -ne "0" ]];then
        end="$p"
    fi

# Onde começar/acabar a tabela, caso "-r" seja definido
    if [ "$r" -eq 1 ]; then
        start=$(( end -1 )) # Começar no fim do array
        end="-1"  # Acabar no inicio do array
        increment="-1"  # Incrementar negatívamente
    fi
```

#### RESULTADOS E TESTES

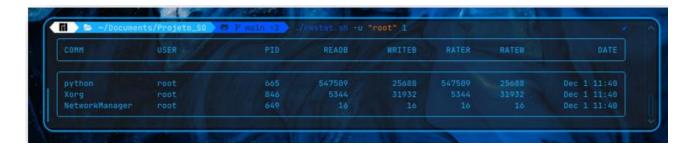
→ Teste com 1 segundo:



→ Teste com restrição do nome do processo (-c spotify)



→ Teste com restrição do nome do utilizador (-u root)



→ Teste com restrição de data de início mínimo do processo (-s "Dec 1 14:30")



→ Teste com restrição de data de início máximo do processo (-s "Dec 1 11:43")



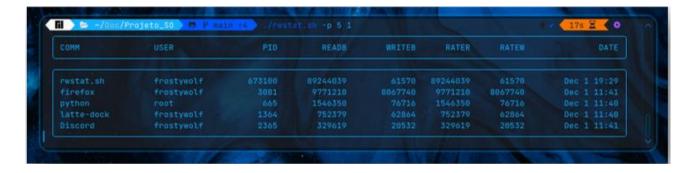
→ Teste com restrição de data de início mínimo e máximo do processo (-s "Dec 1 11:45" -e "Dec 1 18:00")



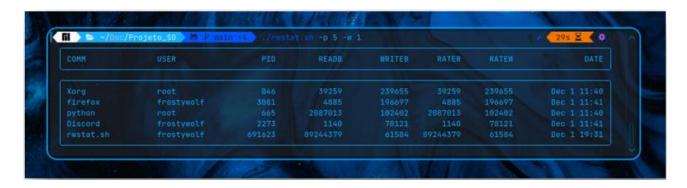
→ Teste com restrição de mínimo e máximo de PID (-m 1000 -M 2000)



 $\rightarrow$  Teste com máximo número de linhas (-p 5)



→ Teste com máximo número de linhas e tabela invertida (-p 5 -r)



 $\rightarrow$  Teste com máximo número de linhas, tabela invertida e ordenado por taxa de leitura (-p 5 -r -w)



→ Teste com pedido de ajuda na utilização (-h)



# CONCLUSÃO

Após corrermos estes testes e muitos mais, em máquinas diferentes e com distribuições Linux diferentes, podemos concluir que todas as operações foram implementadas corretamente e que o programa funciona como o esperado, tendo em conta os objetivos a atingir com o projeto.

Com este projeto pudemos perceber a real potência que a linguagem *bash* tem, pois embora seja bastante simples é possível **utilizar diversas ferramentas e "work arounds"** que nos permitem contruir um projeto de grandes dimensões e facilmente portável para inúmeros sistemas operativos diferentes, tomando partido da personalização e modularidade da *bash*.

Assim sendo, podemos concluir que este trabalho se tornou possível graças ao conhecimento e pratica desenvolvidos nas aulas práticas e teóricas, tanto de *bash* com de tratamento de processos. Valorizamos também as muitas pesquisas que fizemos na web de modo a concluirmos este projeto com sucesso.

### WEBGRAFIA

- > https://stackoverflow.com/
- > <a href="https://unix.stackexchange.com/">https://unix.stackexchange.com/</a>
- > https://askubuntu.com/\_
- > <a href="https://superuser.com/">https://superuser.com/</a>
- > <a href="https://linuxhint.com/">https://linuxhint.com/</a>
- > <a href="https://www.tutorialkart.com/">https://www.tutorialkart.com/</a>